

Fundamentos de Ciencia de Datos — Proyecto Final

ARTÍCULO ACADÉMICO

Sesgos Sociodemográficos y Económicos en la Supervivencia del Titanic: Un Análisis Exploratorio de Datos

Sociodemographic and Economic Biases in Titanic Survival: An Exploratory Data Analysis

Vanessa Tocasuche Ochoa

Ingeniería de Sistemas — Universidad de Antioquia

vanessa.tocasuche@udea.edu.co

Juan Manuel Velásquez Castañeda

Ingeniería de Sistemas — Universidad de Antioquia

juan.velasquezc1@udea.edu.co

Curso: Fundamentos de Ciencia de Datos

Docente: María Bernarda Salazar Sánchez, Ph.D.

Departamento de Ingeniería de Sistemas

Universidad de Antioquia — Medellín, Colombia — Mayo de 2026

1. Resumen

Este artículo presenta un análisis exploratorio de datos (EDA) sobre el conjunto de datos del Titanic, con el objetivo de identificar sesgos sociodemográficos y económicos asociados con la supervivencia de los pasajeros durante el hundimiento del barco ocurrido en 1912. A partir de 891 registros y 12 variables, se aplicaron técnicas de análisis univariado, bivariado y multivariado, complementadas con métodos de detección de datos atípicos basados en el rango intercuartílico (IQR) y transformaciones logarítmicas para el tratamiento de variables con distribuciones asimétricas. La imputación de datos faltantes en *Age* (19.9% nulos) se realizó mediante la mediana agrupada por clase y sexo, mientras que *Embarked* fue completada con la moda. Los resultados evidencian patrones consistentes: las mujeres y los pasajeros de primera clase presentan tasas de supervivencia notablemente superiores, mientras que los pasajeros de tercera clase registran las mayores tasas de mortalidad. Adicionalmente, se construyó la variable derivada *Family_Size*, que reveló que los viajeros en grupos familiares de tamaño moderado tuvieron ventajas de supervivencia frente a los viajeros solitarios. Estos hallazgos sugieren la existencia de desigualdades estructurales que condicionaron el acceso a los medios de rescate.

Palabras clave: análisis exploratorio de datos, Titanic, sesgos sociodemográficos, detección de outliers, imputación de datos, ciencia de datos.

2. Introducción

El hundimiento del RMS Titanic el 15 de abril de 1912 constituye uno de los desastres marítimos más documentados de la historia moderna. A pesar de que factores operativos y técnicos —como la insuficiencia de botes salvavidas— determinaron en gran medida el alto índice de mortalidad, la distribución diferencial de los sobrevivientes sugiere que el desenlace no fue puramente aleatorio (Frey et al., 2011). Investigaciones previas han señalado que variables como la clase socioeconómica del pasajero, el sexo y la edad influyeron significativamente en la probabilidad de sobrevivir (Hall, 1986; Gleicher & Stevans, 1992).

Desde la perspectiva de la ciencia de datos, el conjunto de datos del Titanic representa un recurso canónico para la exploración de técnicas de análisis exploratorio y el estudio de sesgos estructurales en datos reales (Vanderplas, 2016). Este trabajo se enmarca en el curso de Fundamentos de Ciencia de Datos de la Universidad de Antioquia y busca aplicar de forma sistemática el ciclo de vida completo de un proyecto analítico: desde la comprensión del problema hasta la comunicación de resultados, pasando por el preprocesamiento, la exploración y la transformación de los datos.

La pregunta central de investigación es: *¿Existen sesgos sociodemográficos y económicos que presenten una relación (asociación) con el estado de supervivencia de los pasajeros del Titanic,*

y cómo se evidencian estos patrones al evaluar tanto las características originales como las variables transformadas?

El objetivo general es explorar y cuantificar las relaciones entre las características de los pasajeros y su supervivencia, con énfasis en posibles desigualdades estructurales. Los objetivos específicos son: (1) realizar un análisis exploratorio univariado, bivariado y multivariado de las variables seleccionadas; (2) detectar y tratar valores atípicos en las variables numéricas; (3) imputar los datos faltantes y aplicar transformaciones pertinentes; y 4) construir nuevas variables derivadas que potencien el análisis comparativo.

El resto del artículo se organiza de la siguiente manera: la Sección 3 describe la metodología empleada; la Sección 4 presenta el análisis exploratorio de datos, la Sección 5 describe la detección y tratamiento de outliers, la Sección 6 aborda la imputación y transformación, la Sección 7 presenta los resultados e interpretación, la Sección 8 expone las conclusiones y la Sección 9 lista las referencias bibliográficas.

3. Metodología

3.1. Fuente y características del conjunto de datos

El conjunto de datos utilizado corresponde al dataset público Titanic, disponible en la plataforma Kaggle bajo el identificador *yasserh/titanic-dataset* (Yasser, 2022). Fue cargado mediante la librería *kagglehub* con el adaptador de *pandas*, obteniendo un dataframe de 891 filas y 12 columnas. La Tabla 1 resume las variables disponibles, su tipo de dato y el porcentaje de valores faltantes.

Tabla 1. Descripción de variables del conjunto de datos del Titanic.

Variable	Tipo	Valores faltantes	Descripción
Survived	int64	0 / 891 (0%)	Variable objetivo binaria (0 = no, 1 = sí)
Pclass	int64	0 / 891 (0%)	Clase del boleto: 1. ^a , 2. ^a o 3. ^a
Sex	object	0 / 891 (0%)	Sexo del pasajero (male / female)
Age	float64	177 / 891 (19.9%)	Edad en años
SibSp	int64	0 / 891 (0%)	N.º de hermanos / cónyuge a bordo
Parch	int64	0 / 891 (0%)	N.º de padres / hijos a bordo
Fare	float64	0 / 891 (0%)	Tarifa pagada (£)
Embarked	object	2 / 891 (0.2%)	Puerto de embarque (S, C, Q)
Cabin	object	687 / 891 (77.1%)	Número de cabina — excluida del análisis
Name / Ticket	object	0 / 891 (0%)	Identificadores textuales — no usados en EDA

Se seleccionaron ocho variables clave para el análisis: *Survived* (variable objetivo), *Pclass*, *Sex*, *Age*, *SibSp*, *Parch*, *Fare* y *Embarked*. La variable *Cabin* fue excluida por presentar un 77.1% de valores faltantes, lo que la hace estadísticamente poco confiable. Las variables *Name* y *Ticket*, al ser identificadores textuales sin valor analítico directo, no fueron consideradas en el EDA.

3.2. Flujo de trabajo analítico

El presente análisis se desarrolló bajo un enfoque cuantitativo y correlacional, implementando un flujo de trabajo analítico estructurado en cinco etapas: (1) exploración descriptiva univariada, bivariada y multivariada; (2) detección de valores atípicos mediante métodos gráficos (boxplot) y estadísticos (IQR y Z-score); (3) tratamiento de datos faltantes mediante imputación diferenciada según el tipo de variable; (4) escalamiento y transformación de variables numéricas; y (5) ingeniería de características para construir variables derivadas de mayor poder analítico.

3.3. Herramientas y entorno de desarrollo

El análisis se desarrolló en Python sobre Google Colab, utilizando las siguientes librerías: *pandas* (McKinney, 2010) para la manipulación de datos tabulares, *numpy* para operaciones numéricas vectorizadas, *matplotlib* y *seaborn* (Hunter, 2020) para la generación de visualizaciones estadísticas, *scipy.stats* para el cálculo de puntuaciones Z, *sklearn.preprocessing* (Pedregosa et al., 2011) para el escalamiento de variables, y *kagglehub* para la carga del dataset desde la plataforma Kaggle. El código fuente completo se encuentra disponible en el repositorio GitHub del proyecto.

3.4. Criterios para el tratamiento y transformación de variables

- **Age (19.9% nulos):** imputación con la mediana agrupada por *Pclass* y *Sex*, asumiendo que el estatus social y el género condicionan los perfiles etarios.
- **Cabin (77.1% nulos):** eliminación de la columna por carencia de información suficiente para una recuperación estadística confiable.
- **Embarked (<1% nulos):** imputación con la moda ('S', puerto más frecuente).
- **Fare:** transformación logarítmica ($\log_{10}$) para reducir la asimetría positiva extrema sin eliminar los valores reales de boletos de lujo.
- **Age:** escalamiento con *StandardScaler* (media 0, desviación estándar 1) para normalizar la distribución.
- **Fare_Log:** escalamiento con *MinMaxScaler* al rango [0, 1] por haber sido previamente transformada.
- **Family_Size = SibSp + Parch + 1:** variable derivada que sintetiza el tamaño del grupo familiar total a bordo.

4. Análisis Exploratorio de Datos (EDA)

4.1. Análisis univariado

La distribución por clase muestra que la tercera clase concentra el mayor número de pasajeros (491), seguida de la primera (216) y la segunda (184). La distribución por sexo revela una marcada mayoría de pasajeros masculinos (577 hombres frente a 314 mujeres). La variable Age presenta una distribución sesgada positivamente, con la mayoría de pasajeros concentrados entre los 20 y 30 años y una mediana de 28 años. La variable Fare exhibe una distribución fuertemente asimétrica hacia la derecha, con valores que van de £0 a £512, lo cual evidencia la presencia de outliers reales y la necesidad de una transformación. La tasa de supervivencia global es del 38.4% (342 sobrevivientes de 891 pasajeros).




Figura 1. Distribuciones univariadas de las variables principales del dataset Titanic.




Figura 2. Visualización de valores faltantes por variable mediante gráfico de barras de completitud.

4.2. Análisis bivariado

Se evaluó la relación directa de factores socioeconómicos y de género con la variable objetivo Survived. El análisis revela dos patrones dominantes:

Sesgo de género: a pesar de que los hombres eran mayoría en el barco, la tasa de supervivencia de las mujeres superó el 70%, mientras que la de los hombres fue inferior al 20%. Esto confirma una fuerte asociación estructural, consistente con la aplicación diferencial de la norma de 'mujeres y niños primero'.

Sesgo de clase socioeconómica: se observa una correlación decreciente clara entre nivel de clase y supervivencia. Los pasajeros de primera clase presentan la tasa más alta, mientras que los de tercera clase registran la menor, validando la hipótesis de desigualdad en el acceso a los medios de rescate.




Figura 3. Tasas de supervivencia por género (izquierda) y por clase socioeconómica (derecha).

4.3. Análisis multivariado

Para identificar interacciones complejas entre variables, se construyó un mapa de calor de correlaciones de Pearson entre las variables numéricas principales (Survived, Pclass, Age, SibSp, Parch, Fare). Los hallazgos más relevantes son:

- Pclass y Survived: correlación negativa moderada (-0.34), indicando que a menor número de clase (mayor estatus), mayor probabilidad de sobrevivir.
- Fare y Survived: correlación positiva moderada ($+0.26$), coherente con el análisis bivariado.
- Pclass y Fare: correlación negativa fuerte (-0.55), lo que sugiere redundancia informativa entre ambas variables como indicadores de estatus económico.
- Age y Survived: correlación débil (-0.08), indicando que la edad aislada no es un predictor determinante.
- SibSp y Parch: correlación positiva (0.41), lo que indica que las familias tendían a viajar juntas, justificando la creación de la variable `Family_Size`.




Figura 4. Mapa de calor de correlaciones de Pearson entre las variables numéricas del dataset.

4.4. Análisis multivariado ampliado: Género $\times$ Clase $\times$ Supervivencia

La visualización cruzada de género, clase y supervivencia permite identificar patrones de privilegio diferencial que no son visibles en análisis bivariados aislados:

El cruce Género $\times$ Clase revela que **una mujer de 3.ª clase** tenía mayor tasa de supervivencia ($\sim 50\%$) que un **hombre de 1.ª clase** ($\sim 37\%$), confirmando que el género fue el factor determinante por encima del estatus económico. El violin plot muestra que en 1.ª clase los pasajeros de mayor edad sobrevivieron en mayor proporción, mientras que en 3.ª clase la distribución etaria de sobrevivientes y fallecidos es prácticamente idéntica, lo que sugiere que la edad importó menos que la clase en los deciles inferiores.




Figura 5. Heatmap de supervivencia por género y clase (izquierda) y violin plot de edad por clase y supervivencia (derecha).

5. Detección y Tratamiento de Datos Atípicos

Se identificaron anomalías en las variables continuas Fare y Age mediante métodos gráficos y estadísticos.

5.1. Detección en Fare

El método del Rango Intercuartílico (IQR) calculó un límite superior de \$65.63, detectando **116 outliers** (13.0% del dataset). El método Z-score ($|z| > 3$) identificó **20 outliers extremos**. Las cinco tarifas más altas del dataset superan los £512, correspondientes a boletos de camarotes de lujo de primera clase.

Decisión: los outliers en Fare no son eliminados, dado que representan tarifas reales de boletos de lujo. En su lugar, se aplica una transformación logarítmica ($np.log1p$) que reduce la asimetría positiva extrema de 4.787 a 0.449 y estabiliza la varianza sin pérdida de información.




Figura 6. Comparación de boxplots de la variable Fare antes y después de la transformación logarítmica ($\log1p$).

5.2. Detección en Age

El método IQR detectó valores por fuera del rango $[-1.0, 65.0]$ años en la variable Age. No obstante, dado que corresponden a niños muy pequeños y adultos mayores que efectivamente viajaban en el barco, no se eliminaron. Se conservan como valores válidos y son tratados en la fase de imputación.

6. Imputación, Escalamiento y Transformación de Datos

6.1. Imputación de datos faltantes

Variable Age (19.9% nulos): para no alterar la distribución demográfica, se rechazó la imputación por la media global. En su lugar, se utilizó la **mediana agrupada por Pclass y Sex**, asumiendo que el estatus social y el género condicionan los perfiles etarios. Este enfoque respeta la heterogeneidad entre grupos.

Variable Cabin (77.1% nulos): dada la carencia extrema de información que imposibilita una recuperación estadística confiable, se procedió a su eliminación del dataset para reducir la dimensionalidad y evitar ruido en el análisis.

Variable Embarked (<1% nulos): los dos registros faltantes fueron imputados con el valor más frecuente (moda = 'S', Southampton), dado el bajo impacto de esta decisión sobre el análisis global.

6.2. Ingeniería de características

A partir de la exploración multivariada, se generó la variable *Family_Size* sumando los hermanos/cónyuges (*SibSp*), padres/hijos (*Parch*) y el propio pasajero (+1). Esta variable sintetiza el tamaño del grupo familiar total a bordo y permite analizar si existió un sesgo hacia las personas que viajaban sin acompañantes.

6.3. Escalamiento de variables numéricas

Se aplicaron dos estrategias de escalamiento complementarias: **StandardScaler** sobre Age (normaliza hacia media ≈ 0 y desviación estándar ≈ 1 , respetando la distribución aproximadamente normal), y **MinMaxScaler** sobre Fare_Log (comprime el rango a $[0, 1]$, apropiado dado que ya fue transformada logarítmicamente). La verificación post-escalamiento confirmó que Age_Scaled presenta media ≈ 0.000 y std ≈ 1.000 , y Fare_Log_Scaled presenta mín = 0.000 y máx = 1.000.




Figura 7. Verificación visual de las distribuciones tras el escalamiento de Age (izquierda) y Fare_Log (derecha).

6.4. Codificación de variables categóricas

Se aplicó codificación binaria (*LabelEncoder*) a la variable Sex (female = 0, male = 1), y codificación one-hot (*pd.get_dummies*) a Embarked, generando las columnas dummy *Emb_Q* y *Emb_S*. El dataset final, con todas las transformaciones aplicadas, alcanza un shape de 891 filas y 18 columnas.

7. Resultados e Interpretación

7.1. Supervivencia según tamaño de familia

El análisis de la variable *Family_Size* reveló un patrón en forma de U invertida: los pasajeros que viajaban solos (*Family_Size* = 1) presentaron tasas de supervivencia por debajo de la media global (38.4%), mientras que los grupos familiares de tamaño moderado (2–4 integrantes) registraron las tasas más altas. Los grupos de tamaño grande (5 o más) volvieron a presentar tasas inferiores, posiblemente por la dificultad de coordinar la evacuación de grupos numerosos. La Tabla 2 resume las tasas de supervivencia por subgrupo demográfico.




Figura 8. Tasa de supervivencia según el tamaño del grupo familiar. La línea roja indica la media global (38.4%).

Tabla 2. Tasas de supervivencia por subgrupo sociodemográfico.

Subgrupo	Tasa de supervivencia
Mujeres	~74%
Hombres	~19%
Clase 1	~63%
Clase 2	~47%
Clase 3	~24%
Viajero solo (Family_Size = 1)	~30%
Familia mediana (Family_Size 2–4)	~57%
Familia grande (Family_Size ≥ 5)	~16%

Nota. Tasas aproximadas calculadas a partir del dataset de entrenamiento (891 registros).

7.2. Efecto de la transformación logarítmica sobre Fare

La transformación $\log_{1p}$ sobre la variable Fare redujo la asimetría (skewness) de **4.787** a **0.449**, normalizando su distribución. Este resultado valida la pertinencia de la transformación: los valores originales concentraban la información en los percentiles superiores, distorsionando cualquier análisis basado en distancias o regresiones lineales. La distribución transformada permite una comparación más equitativa entre grupos de pasajeros.




Figura 9. Distribución de la tarifa pagada: original con asimetría positiva extrema (izquierda) y transformada logarítmicamente (derecha).

7.3. Síntesis de hallazgos clave

Los resultados del análisis exploratorio permiten establecer los siguientes hallazgos:

- Sesgo de género: la variable Sex es el predictor más fuerte de supervivencia. La tasa de supervivencia femenina (~74%) triplica a la masculina (~19%), superando incluso el efecto de la clase socioeconómica.
- Desigualdad estructural (clase y tarifa): la mortalidad se concentró asimétricamente en el estrato socioeconómico más bajo. La normalización matemática de Fare y su cruce con Pclass corroboran que el poder adquisitivo facilitó el acceso diferencial a la seguridad.
- Factor familiar: los viajeros solitarios actuaron como un grupo de riesgo, mientras que pertenecer a un núcleo familiar moderado funcionó como una ventaja logística durante la evacuación.
- Interacción clase-género: los efectos de género y clase se amplifican mutuamente. Una mujer de 3.^a clase superó en tasa de supervivencia a un hombre de 1.^a clase, lo que confirma la primacía del género en la jerarquía de factores de riesgo.

8. Conclusiones

El presente análisis exploratorio proporciona evidencia estadística suficiente para responder afirmativamente a la pregunta de investigación: existen marcados sesgos sociodemográficos y económicos fuertemente asociados a la supervivencia de los pasajeros del Titanic.

Principales contribuciones: (i) la sistematización del proceso analítico bajo el ciclo de vida completo de la ciencia de datos; (ii) la cuantificación de las correlaciones entre variables sociodemográficas y supervivencia mediante técnicas bivariadas y multivariadas; (iii) el tratamiento diferenciado de outliers reales mediante transformación logarítmica, preservando la integridad informativa del dataset; y (iv) la construcción de la variable derivada Family_Size, que reveló un patrón no evidente en las variables originales y enriquece la comprensión del fenómeno.

Limitaciones: el carácter incompleto de la variable Age (19.9% de valores nulos) introduce una fuente de incertidumbre en los análisis etarios, aunque fue mitigada con imputación agrupada. La exclusión de Cabin por alta proporción de faltantes implica la pérdida de información sobre la ubicación física del pasajero en el barco, que podría ser relevante para entender patrones de acceso a los botes salvavidas. El enfoque correlacional del análisis no permite establecer relaciones causales definitivas.

Líneas de trabajo futuro: (i) aplicar modelos de clasificación supervisada (regresión logística, árbol de decisión, random forest) para cuantificar el poder predictivo de cada variable y evaluar la robustez de los hallazgos; (ii) incorporar técnicas de reducción de dimensionalidad (PCA, t-SNE) para explorar la estructura latente del dataset; (iii) extender el análisis a técnicas de

detección de sesgos algorítmicos orientadas a la equidad en machine learning; y (iv) explorar el uso de modelos de imputación múltiple para la variable Age como alternativa al enfoque de mediana agrupada.

Este estudio demuestra cómo la adecuada preparación, transformación y exploración de los datos permite extraer realidades sociológicas ocultas en variables en bruto, garantizando un análisis objetivo y profesional exento de sesgos narrativos. La transparencia en el tratamiento de los datos y la documentación sistemática de cada decisión analítica constituyen pilares fundamentales de la responsabilidad ética en la ciencia de datos.

9. Referencias

- Frey, B. S., Savage, D. A., & Torgler, B. (2011). Noblesse oblige? Determinants of survival in a life-and-death situation. *Journal of Economic Behavior & Organization*, 74(1–2), 1–11. <https://doi.org/10.1016/j.jebo.2010.02.005>
- Gleicher, D., & Stevans, L. K. (1992). Who did not survive the Titanic? A sociological analysis of who made it off the doomed liner. *Free Inquiry in Creative Sociology*, 20(2), 219–226.
- Hall, W. (1986). Social class and survival on the S.S. Titanic. *Social Science & Medicine*, 22(6), 687–690. [https://doi.org/10.1016/0277-9536\(86\)90041-9](https://doi.org/10.1016/0277-9536(86)90041-9)
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61). SciPy.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Vanderplas, J. (2016). *Python data science handbook: Essential tools for working with data*. O'Reilly Media.
- Yasser, H. (2022). *Titanic dataset* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/yasserh/titanic-dataset>